

Aprendizagem de Máquina

Aprendizagem Bayesiana

Luiz Eduardo S. Oliveira

Universidade Federal do Paraná
Departamento de Informática
<http://web.inf.ufpr.br/luizoliveira>

Introdução

- O pensamento Bayesiano fornece uma abordagem probabilística para a aprendizagem.
- Está baseado na suposição de que as quantidades de interesse são reguladas por distribuições de probabilidades.
- Quantificar o custo/benefício entre diferentes decisões de classificação usando probabilidades e custos associados a classificação.
- Teorema de Bayes
 - ▶ Mostra como alterar as probabilidades a priori tendo em conta novas evidências de forma a obter probabilidades a posteriori.


Terminologia

- Classes ω_i (variável aleatória)
- Probabilidades a priori $P(\omega_i)$
 - ▶ Conhecimento a priori que se tem sobre o problema, ou seja, conhecimento a priori sobre a aparição de exemplos das classes do problema.
- Função de Densidade Probabilidade $P(x)$
 - ▶ Frequência com a qual encontramos uma determinada característica
 - ▶ Evidências

Terminologia

- Densidade de Probabilidade Condicional

- ▶ $P(x|\omega_j)$ (Likelihood)
- ▶ Frequência com que encontramos uma determinada característica dado que a mesma pertence a classe ω_j




Densidade de duas classes em que x representa uma característica qualquer.

Terminologia

- Probabilidade a posteriori
 - ▶ $P(\omega_j|x)$
 - ▶ Probabilidade que o padrão pertença a classe ω_j dada a característica x
- Regra de decisão baseada apenas em priors
 - ▶ ω_1 , se $P(\omega_1) > P(\omega_2)$
 - ▶ ω_2 , caso contrário.

Tomando decisão usando Bayes



Probabilidades a posteriori calculadas usando $P(\omega_1) = 2/3$ e $P(\omega_2) = 1/3$. Nesse caso, para um valor de $x = 14$, a probabilidade do padrão pertencer a ω_2 é de 0.08, enquanto que a probabilidade do padrão pertencer a ω_1 é de 0.92.

Para cada x , as probabilidades a posteriori somam 1.

$$P(\omega_1|14) = \frac{0.2 \times 2/3}{0.2 \times 2/3 + 0.04 \times 1/3} = 0.92$$

Teorema de Bayes

- Basicamente o teorema de Bayes mostra como rever as crenças sempre que novas evidências são coletadas.
- Ou seja, atualizar a probabilidade a posteriori utilizando para isso a probabilidade a priori e as verossimilhanças e as evidências

$$P(A|B) = \frac{P(A) \times P(B|A)}{P(B)}$$

- $P(A|B)$ é a probabilidade a posteriori
- $P(A)$ é a probabilidade a priori
- $P(B|A)$ são as verossimilhanças (likelihood)
- $P(B)$ são as evidências, dado por $\sum P(A_i) \times P(B|A_i)$

Exemplo

- Um médico sabe que a meningite causa torcicolo em 50% dos casos. Porém, o médico sabe que a meningite atinge $1/50000$ e também que a probabilidade de se ter torcicolo é de $1/20$.
- Usando Bayes pra saber a probabilidade de uma pessoa ter meningite dado que ela está com torcicolo

Exemplo

- Um médico sabe que a meningite causa torcicolo em 50% dos casos. Porém, o médico sabe que a meningite atinge 1/50000 e também que a probabilidade de se ter torcicolo é de 1/20.
- Usando Bayes pra saber a probabilidade de uma pessoa ter meningite dado que ela está com torcicolo

Temos então

- $P(T|M) = 0.5$
- $P(M) = 1/50000$
- $P(T) = 1/20$

$$P(M|T) = \frac{P(M) \times P(T|M)}{P(T)} = \frac{1/50000 \times 0.5}{1/20} = 0.0002$$

Exercício

- Considere o sistema de classificação de peixes. Para essa época do ano, sabe-se que a probabilidade de pescar salmão é maior que pescar robalo, $P(salmaa) = 0.82$ e $P(robabo) = 0.18$.
- Suponha que a única característica que você pode contar é a intensidade do peixe ou seja, se ele é claro ou escuro. Sabe-se que 49.5% dos salmões tem intensidade clara e que 85% dos robalos tem intensidade clara.
- Calcule a probabilidade de ser salmão dado que o peixe pescado tem intensidade clara.

Exercício

- Considere o sistema de classificação de peixes. Para essa época do ano, sabe-se que a probabilidade de pescar salmão é maior que pescar robalo, $P(\text{salmao}) = 0.82$ e $P(\text{robabo}) = 0.18$.
- Suponha que a única característica que você pode contar é a intensidade do peixe ou seja, se ele é claro ou escuro. Sabe-se que 49.5% dos salmões tem intensidade clara e que 85% dos robalos tem intensidade clara.
- Calcule a probabilidade de ser salmão dado que o peixe pescado tem intensidade clara.

$$P(S|C) = \frac{P(S) \times P(C|S)}{P(C)} = \frac{0.82 \times 0.495}{0.82 \times 0.495 + 0.18 \times 0.85} = 0.726$$

Classificador Naïve Bayes

- Um dos algoritmos de aprendizagem mais práticos e utilizados na literatura.
- Denominado Naïve (ingênuo) por assumir que os atributos são condicionalmente independentes, ou seja, a informação de um evento não é informativa sobre nenhum outro.
- Apesar dessa premissa, o classificador reporta bom desempenho em diversas tarefas de classificação.
- Aplicações bem sucedidas:
 - ▶ Diagnóstico
 - ▶ Classificação de documentos textuais

Classificador Naïve Bayes

- Se aplica a tarefas de aprendizagem onde cada instância x é descrita por um conjunto de valores de atributos em que a função alvo, $f(x)$ pode assumir qualquer valor de um conjunto V .
- Um conjunto de exemplos de treinamento da função alvo é fornecido a uma nova instância é apresentada, descrita pela tupla de valores de atributos $\langle a_1, a_2, \dots, a_n \rangle$.
- A tarefa é prever o valor alvo (ou classificação) para esta nova instância.

Classificador Naïve Bayes

- O classificador é baseado na suposição de que os valores dos atributos são condicionalmente independentes dados o valor alvo.
- Se usarmos Bayes para múltiplas evidências, temos

$$P(H|E_1, E_2, \dots, E_n) = \frac{P(E_1, E_2, \dots, E_n|H) \times P(H)}{P(E_1, E_2, \dots, E_n)}$$

- Considerando a hipótese de independência, podemos re-escrever o teorema de Bayes da seguinte forma:

$$P(H|E_1, E_2, \dots, E_n) = \frac{P(E_1|H) \times P(E_2|H) \times \dots \times P(E_n|H) \times P(H)}{P(E_1, E_2, \dots, E_n)}$$

O denominador pode ser ignorado por se tratar de um termo comum.

Exemplo

Para entender melhor o considere o seguinte problema:

| | outlook | temperature | humidity | windy | play |
|----|----------|-------------|----------|-------|------|
| 1 | sunny | hot | high | false | no |
| 2 | sunny | hot | high | true | no |
| 3 | overcast | hot | high | false | yes |
| 4 | rainy | mild | high | false | yes |
| 5 | rainy | cool | normal | false | yes |
| 6 | rainy | cool | normal | true | no |
| 7 | overcast | cool | normal | true | yes |
| 8 | sunny | mild | high | false | no |
| 9 | sunny | cool | normal | false | yes |
| 10 | rainy | mild | normal | false | yes |
| 11 | sunny | mild | normal | true | yes |
| 12 | overcast | mild | high | true | yes |
| 13 | overcast | hot | normal | false | yes |
| 14 | rainy | mild | high | true | no |

Construindo o Modelo (NB)

O primeiro passo consiste em construir o modelo de probabilidades condicionais Naïve Bayes (NB)

| Outlook | | | Temperature | | | Humidity | | | Windy | | | Play | |
|----------|---|---|-------------|---|---|----------|---|---|--------|---|---|------|----|
| Yes No | | | Yes No | | | Yes No | | | Yes No | | | Yes | No |
| Sunny | 2 | 3 | Hot | 2 | 2 | High | 3 | 4 | False | 6 | 2 | 9 | 5 |
| Overcast | 4 | 0 | Mild | 4 | 2 | Normal | 6 | 1 | True | 3 | 3 | | |
| Rainy | 3 | 2 | Cool | 3 | 1 | | | | | | | | |

- A tabela acima contém a frequência de diferentes evidências.
- Por exemplo, existem duas instâncias mostrando (outlook=sunny) para (jogar=yes)

Avaliação

Após definir todas as frequências é necessário calcular todas as probabilidades condicionais e as probabilidades a priori.

| Outlook | | | Temperature | | | Humidity | | | Windy | | | Play | |
|----------|-----|-----|-------------|-----|-----|----------|-----|-----|-------|-----|-----|------|------|
| Yes | No | | Yes | No | | Yes | No | | Yes | No | | Yes | No |
| Sunny | 2/9 | 3/5 | Hot | 2/9 | 2/5 | High | 3/9 | 4/5 | False | 6/9 | 2/5 | 9/14 | 5/14 |
| Overcast | 4/9 | 0/5 | Mild | 4/9 | 2/5 | Normal | 6/9 | 1/5 | True | 3/9 | 3/5 | | |
| Rainy | 3/9 | 2/5 | Cool | 3/9 | 1/5 | | | | | | | | |

Por exemplo:

- $P(\text{outlook}=\text{sunny}|\text{play}=\text{yes}) = 2/9$
- $P(\text{play}=\text{yes}) = 9/14$

Predição

- De posse do modelo, podemos usá-lo para prever um evento “play” com base em um conjunto qualquer de evidências.
- Por exemplo: [Sunny,Cool,High,True,?]

$$\begin{aligned}P(\text{Yes}|E) = & (P(\text{Outlook} = \text{sunny}|\text{Yes}) \times \\& P(\text{Temp} = \text{Cool}|\text{Yes}) \times \\& P(\text{Humidity} = \text{High}|\text{Yes}) \times \\& P(\text{Windy} = \text{True}|\text{Yes}) \times \\& P(\text{Yes}))/P(E)\end{aligned}$$

$P(E)$ pode ser ignorada por se tratar de um denominador comum quando queremos comparar as duas classes. Deste modo, temos

$$P(\text{Yes}|E) = \frac{2}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14}$$

Predição

Calculando a predição para as duas classes

- Para “Yes” temos $\frac{2}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14} = 0.0053$
- Para “No” temos $\frac{3}{5} \times \frac{1}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{5}{14} = 0.0206$

Convertendo esses valores para probabilidade através da normalização, temos

- $P(\text{Yes}|E) = 0.0053 / (0.0053 + 0.0206) = 0.205$
- $P(\text{No}|E) = 0.0206 / (0.0053 + 0.0206) = 0.795$

Técnica de Suavização

- Em alguns casos, a frequência pode ser zero, como por exemplo $P(\text{outlook}=\text{overcast}|\text{play}=\text{No}) = 0/5$.
- Isso cria um problema para calcular $P(\text{No})$, a qual será sempre zero quando esta evidência for utilizada.
- A técnica de suavização mais utilizada é a estimação de Laplace, a qual é dada

$$P'(H|E) = \frac{n_c + \mu p}{n + \mu}$$

- n_c é o número de hipóteses existentes para a classe (Ex: Zero para $\text{outlook}=\text{overcast}$ e $\text{play}=\text{no}$)
- n número de exemplos totais para o treinamento
- μ número de exemplos virtuais
- Considerado que as evidências são igualmente distribuídas, $p = \frac{1}{3}$ (sunny, overcast, rainy)

Técnica de Suavização

Reestimando os valores usando Laplace, teríamos

- $P(\text{outlook} = \text{Sunny} | \text{play} = \text{No}) = \frac{3+3 \times 1/3}{5+3} = \frac{4}{8}$
- $P(\text{outlook} = \text{Overcast} | \text{play} = \text{No}) = \frac{0+3 \times 1/3}{5+3} = \frac{1}{8}$
- $P(\text{outlook} = \text{Rainy} | \text{play} = \text{No}) = \frac{2+3 \times 1/3}{5+3} = \frac{3}{8}$

Desta forma, todos os valores foram redistribuídos mantendo uma proporção similar

Calculando as probabilidade para atributos contínuos

Existem duas maneiras

- Discretizar os atributos contínuos em algumas categorias. Por exemplo, temperatura acima de 80F pode ser considerada alta.
- Outra forma consiste em usar uma função de densidade probabilidade e desta forma preservar os valores contínuos.
 - ▶ Nesse caso assumimos que as variáveis contínuas seguem uma distribuição normal
 - ▶ Com isso em mente, podemos calcular a média e desvio de cada variável usando a base de aprendizagem.
 - ▶ De posse da média e desvio, basta aplicar a formula da normal para estimar a probabilidade

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- `scipy.stats.norm(μ, σ).pdf(x)`

Exemplo

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Normal distribution

| | | Humidity | | | | | | | | | | Mean | StDev |
|-----------|-----|----------|----|----|----|----|----|----|----|----|------|------|-------|
| Play Golf | yes | 86 | 96 | 80 | 65 | 70 | 80 | 70 | 90 | 75 | 79.1 | 10.2 | |
| | no | 85 | 90 | 70 | 95 | 91 | | | | | 86.2 | 9.7 | |

$$P(\text{humidity} = 74 | \text{play} = \text{yes}) = \frac{1}{\sqrt{2\pi}(10.2)} e^{-\frac{(74-79.1)^2}{2(10.2)^2}} = 0.0344$$

$$P(\text{humidity} = 74 | \text{play} = \text{no}) = \frac{1}{\sqrt{2\pi}(9.7)} e^{-\frac{(74-86.2)^2}{2(9.7)^2}} = 0.0187$$

Exercício

| Attribute | Class | |
|-------------|---------------|--------------|
| | yes (0.63) | no (0.38) |
| ===== | | |
| outlook | | |
| sunny | 3.0 | 4.0 |
| overcast | 5.0 | 1.0 |
| rainy | 4.0 | 3.0 |
| [total] | 12.0 | 8.0 |
| temperature | | |
| mean | 72.9697 | 74.8364 |
| std. dev. | 5.2304 | 7.384 |
| weight sum | 9 | 5 |
| precision | 1.9091 | 1.9091 |
| humidity | | |
| mean | 78.8395 | 86.1111 |
| std. dev. | 9.8023 | 9.2424 |
| weight sum | 9 | 5 |
| precision | 3.4444 | 3.4444 |
| windy | | |
| TRUE | 4.0 | 4.0 |
| FALSE | 7.0 | 3.0 |
| [total] | 11.0 | 7.0 |

Calcular a probabilidade para

$E = [\text{Outlook}=\text{rainy}, \text{Temp}=65, \text{Humid}, 70, \text{Wind}=\text{True}]$

$P(\text{Yes}|E) = ?$

$P(\text{No}|E) = ?$